

Úvod do databázových systémů

Kapitola 2

Data a informace, modelování reality,
databázový přístup

Data a informace

- tradiční úloha počítačů
 - (hromadné) zpracování dat
- **data** = naměřené údaje, výsledky pozorování, množiny znaků, množiny čísel...
- **informace** = interpretace dat a vztahů mezi nimi

Data a informace

- data

- 8110067613 je jakési číslo

- informace

- 8110067613 je rodné číslo osoby jménem Jindřich Málek (... interpretace daného čísla, co kdyby to bylo třeba telefonní číslo?)

- příklad nutnosti správné interpretace fontu – znakům abecedy jsou přiřazena čísla ve znakové sadě, neznáme-li použitou znakovou sadu, nepřečteme text (anebo máme ø místo ř)

Data a informace

- data
 - je třeba je nějak uspořádat
 - a zpracovat
- informace
 - výsledek zpracování dat

Modelování reality

- data....

- data obvykle popisují nějaké objekty či jevy reálného světa
 - např. kartotéka pacientů; záznamy o jejich léčbě; seznam lékařů; indikace, kdo koho kdy ošetřil
- každý objekt/jev, který chceme evidovat, popisujeme jeho vlastnostmi – atributy
 - pacient má: rodné číslo, jméno, bydliště, pojišťovnu, ...
 - lékař má: jméno, číslo licence, specializaci, ...
- objekty/jevy často mají mezi sebou vazby
 - pacient je registrován u lékaře
 - lékař učinil zápis do záznamu o léčbě

Modelování reality

- ukládání dat

- neukládáme každý individuální objekt nezávisle, ale identifikujeme **kategorie** objektů stejného druhu
 - zjevně by nebylo logické u každého pacienta uchovávat jinou množinu vlastností
 - zavedeme tedy kategorii (**entitu, třídu**) – PACIENT
 - do této „příhrádky“ pak budeme dávat všechny pacienty
 - všechny objekty v dané kategorii mají stejnou sadu atributů
 - každý objekt v dané kategorii je ovšem unikátní a jednoznačně identifikovatelný a odlišitelný od ostatních

Modelování reality

- ukládání dat

- aby data byla uložena úsporně a dalo se s nimi efektivně manipulovat, je třeba v počítači vytvořit vhodný *obraz* popisovaného úseku reality

- **model**

- model není dán jednoznačně, závisí na úhlu pohledu a úrovni detailu, nicméně vždy musí „pasovat“ na naši realitu

- model mimo jiné řeší

- jaké obecné kategorie objektů (entity, třídy) budeme v systému mít
 - jaké popisné atributy budeme u každé kategorie objektů uchovávat
 - jaké budou vztahy mezi kategoriemi objektů

Modelování reality

- objektu reálného světa tedy přísluší nějaký objekt v databázi či informačním systému
 - je třeba zvolit vhodnou reprezentaci
 - datové typy, vnitřní struktura, ...
 - abstrakce
 - zobecnění, výběr podstatných vlastností (atributů)
 - zanedbání vlastností, jež nejsou pro náš účel podstatné
- reprezentace
 - **digitální** – vše se nějak převede na čísla a jejich posloupnosti či struktury

Modelování reality

- reprezentace nejjednodušších údajů
 - čísla, řetězce znaků
 - ani zde není často reprezentace jednoduchá
 - např. konečným dekadickým zápisem čísla nelze dokonale reprezentovat číslo $1/3$

Modelování reality

- reprezentace komplexnějších objektů
 - množství elementárních atributů, reprezentovatelných např. číslem, textovým popisem apod.
 - relativně jednoduché jsou ještě např. fyzikální objekty
 - zvuk, elektrický signál – reprezentace časovým průběhem nebo spektrem
 - barva – reprezentace třeba souřadnicemi RGB
- složitější
 - ...osoby, zvířata v zoo, budovy, zboží, faktury...
 - jejich reprezentace závisí na úhlu pohledu

Modelování reality

- reprezentace komplexnějších objektů
 - ze všech atributů je třeba vybrat ty, které nás zajímají a mají pro nás smysl
 - například v evidenci zaměstnanců továrny nebudeme uchovávat informaci o jejich porodní váze, ale o počtu jejich dětí ano
 - v evidenci novorozenců budeme uchovávat porodní váhu, ale nikoli informaci o počtu jejich dětí (vždy nula)
 - v evidenci nádraží pro účely správy železniční cesty budeme uchovávat počet dopravních kolejí, ale nikoli stavební sloh výpravní budovy
 - v evidenci nádraží pro účely národního památkového ústavu nebudeme uchovávat počet kolejí, ale stavební sloh výpravní budovy ano

Modelování reality

- vztahy mezi objekty
 - například místnosti se nalézají v budově
 - nadřízený má pod sebou zaměstnance
- někdy je obtížné odlišit vlastnost objektu od vztahu s jiným objektem (podrobně viz přednáška o konceptuálním modelování)

Hromadné zpracování dat

- máme reprezentace objektů a jejich vztahů, co s nimi dál?
- systémy pro zpracování dat
 - sběr, uchování, vyhledání a zpracování dat za účelem poskytnutí informací
 - výběr informace
 - prognózy vývoje
 - plánování
 - rozhodování
 - použití pro automatizaci inženýrských prací
 - použití pro zpracování ekonomických agend

Hromadné zpracování dat

- prudký nárůst množství dat, která je nutno spravovat => databázový přístup
- způsoby pořádání dat
 - papírové kartotéky, diář, šanon
 - množiny souborů (souborový přístup) a tabulky
 - databáze

Nevýhody klasických přístupů

- papírové kartotéky
 - uspořádání podle jediného kriteria (například jméno)
 - vyhledání podle jiného kriteria (např. rodného čísla) je obtížné a zahrnuje často procházení všech záznamů
 - komplexnější vyhledávání podle více kriterií je ještě obtížnější

Nevýhody klasických přístupů

- množiny souborů

- soubory obsahují surová data; jejich popis, struktura a interpretace je „skryta“ v aplikačních programech, které se soubory pracují

- redundance a nekonzistence

- opakování dat v různých souborech (duplicity, redundance)

- nekonzistence = dvě kopie týchž dat nejsou stejné

- obtížný přístup

- každý nový typ požadavku (dotazu) vyžaduje zásah programátora - nepružné

Nevýhody klasických přístupů

- množiny souborů

- izolace dat

- data nejsou provázána, navíc mohou být uložena v různých formátech

- problémy s víceuživatelským přístupem

- problémy s ochranou dat

- problémy s integritou dat

- data podléhají přirozeným **integritním omezením** (např. jméno je řetězec znaků), jejichž splnění je obtížné zaručit
 - data pak neodpovídají situaci z reálného světa
 - kontrola vstupu musí být součástí aplikačních SW

Nevýhody klasických přístupů

- množiny souborů
 - programy a data jsou vzájemně závislé
 - pokud je nutné změnit organizaci dat, je třeba tyto změny promítnout do všech programů, které s daty pracují.
 - nízké prostředky pro tvorbu vazeb mezi daty
 - např. odkazování pomocí ukazatelů je plně v rukou programátora – technicky složité, zdlouhavé, náchylné k chybám

Databázový přístup

- řeší výše uvedené nevýhody
- snaha umožnit efektivní přístup k libovolné podmnožině uložených dat
 - obtížné
- odtržení definic dat, struktury dat a manipulace s daty od uživatelských programů
 - struktura dat je předem dána a je uložena spolu s vlastními daty
- související data nejsou uložena v separátních souborech, ale v organizované, centrálně řízené struktuře – **databázi** (DB)

Výhody databázové technologie

- efektivní přístup k datům
 - data je možné vyhodnocovat různými způsoby
- zamezení redundance dat
 - snadnější údržba a zachování konzistence (data v databázi se musejí nacházet v konzistentním, tj. bezesporném stavu)
 - snížení celkového objemu dat
- možnost zabezpečit integritu dat
 - možnost kontroly vstupujících údajů na úrovni DB a ne pouze na úrovni aplikace
 - DB tak může eliminovat případný vliv nejednotné implementace validačních pravidel různých klientů
- sdílení dat
 - možnost paralelního přístupu k datům

Výhody databázové technologie


- ochrana dat před zneužitím
 - rozvinutá bezpečnostní politika
- nezávislost dat na aplikaci
 - datové soubory jsou striktně odděleny od aplikační části a spravují se společně
 - aplikace se při vhodném návrhu DB nemusí starat o detaily uložení dat, vzniká vícevrstvá architektura
 - neizolovanost dat – data jsou uložena na stejném místě ve stejném formátu
 - přístup k datům je možný pouze prostřednictvím rozhraní databázového stroje
- řízená správa dat a zálohování
- zotavení po chybě

Databázový systém

- základní paradigma
 - existence dat v DB je nezávislá na aplikačních programech
 - databáze je definovaná svým schematem
- správa databáze je zajišťována centrálním programem nazývaným *Systém řízení báze dat* (SŘBD) – *database management system* (DBMS)
 - RDBMS – relační
 - ODBMS – objektový
 - ORDBMS – objektově-relační
 - různé SŘBD: Oracle, MySQL, SyBase...

Databázový systém

- **databázový systém** (DBS) je tvořen **databází** a **SŘBD**: $\text{DBS} = \text{DB} + \text{DBMS}$
 - DBMS zapouzdřuje data, data jsou přístupná (libovolné) aplikaci **pouze** prostřednictvím specializovaného rozhraní daného DBMS (například jazyk SQL)



Databázový systém

- každá databáze obsahuje

- data

- konkrétní datové prvky

- elementární hodnoty, např. jméno, rodné číslo, obrázek

- konkrétní vztahy mezi konkrétními datovými prvky

- např. ten a ten vědecký článek napsal ten a ten autor

- metadata – „data o datech“

- schéma

- obecný popis dat a jejich struktury

- konkrétní data do této struktury musí „pasovat“

- integritní omezení (IO)

- podmínky, které musejí data splňovat (např. věk je číslo z intervalu 0 .. 100)

- často jsou zahrnuta už jako součást schematu

DBMS

- poskytuje
 - jazykové prostředky
 - **jazyk pro definici dat** (data definition language, DDL) – prostředky pro popis dat, definici schematu DB, definici integritních omezení, apod.
 - **jazyk pro manipulaci s daty** (data manipulation language, DML) – prostředky pro vkládání, aktualizaci a mazání dat a především pro výběr dat z DB na základě nějakých kritérií.
 - **data control language**, DCL – prostředky pro zajištění ochrany dat, příkazy umožňující definovat práva uživatelů.
 - **transaction control language**, TCL – prostředky pro řízení transakcí

DBMS

- poskytuje
 - řízení víceuživatelského přístupu
 - řízení transakčního zpracování
 - řešení „paralelního“ přístupu k datům – chce-li například jedna transakce číst data, nemůže je jiná v tu chvíli měnit
 - **transakce** je atomická jednotka práce s databází, převádí DB z jednoho konzistentního stavu do druhého, musí být vždy provedena **celá**, nebo vůbec
 - př.: Provádíme-li bankovní převod, peníze se musí odečíst ze zdrojového účtu, ale musí se také přičíst na účet cílový. Dojde-li uprostřed zpracování k výpadku, zdrojový účet musí být ve stejném stavu jako před započítáním transakce

DBMS

- poskytuje
 - zotavení z chyb
 - souvisí mj. s transakčním zpracováním, prováděné elementární operace jsou žurnálovány (log file), pokud se transakce nezdaří, je na základě žurnálu obnoven původní stav databáze (rollback)
 - utajení dat
 - řízení katalogu dat a paměti
- optimalizace zpracování požadavků
 - daný dotaz lze vyhodnocovat různě, SŘBD má vybrat ten nejefektivnější způsob
- pozor, ne každý SŘBD poskytuje všechny výše uvedené prostředky...

Uživatelé databázového systému

- správce (admin)
- aplikační programátor (tvůrce aplikací)
- příležitostný uživatel
- naivní uživatel

Jaká by měla být data v DB

- **perzistentní,**

- přetrvávají nezávisle na aplikacích, na tom, zda se s nimi pracuje či ne

- **spolehlivá**

- **integrita** databáze

- stav, kdy jsou data správná, konzistentní a aktuální
- data musejí musejí splňovat určitá omezení: například v databázi učeben v areálu VŠ musí být každé učebně přiřazena budova, kde sídlí, jinak jde o nekompletní nebo osiřelá data
- může být narušena chybami SW, HW či špatným návrhem databázového schématu

- **bezpečnost** dat – data musejí být chráněna před neoprávněným přístupem

Jaká by měla být data v DB

- **neredundantní** – jedna informace není zbytečně uložena vícekrát
 - např. chceme-li evidovat, že ve Stavovském divadle se hraje Don Giovanni, Rigoletto a Prodaná nevěsta, je nutné mít prvek „Stavovské divadlo“ uložen třikrát?
 - obtížně dosažitelné, ne vždy výhodné
 - obvyklá analogie principu neurčitosti: buď data zabírají mnoho prostoru a jsou rychle dosažitelná nebo naopak, oboje současně nelze splnit
- klíčový pojem v konceptuálním modelování, více viz další přednášky

Jaká by měla být data v DB

■ sdílená

- manipuluje s nimi více uživatelů současně
 - nutno řešit uživatelská oprávnění
- je nutné řešit otázku současného přístupu k týmž datům
 - transakční zpracování
 - nesmí dojít k porušení integrity a konzistence DB

■ nezávislá

- lze změnit fyzickou reprezentaci dat, aniž by se muselo měnit databázové schema či přepisovat aplikační SW
- lze změnit část databázového schematu bez nutnosti změn celého aplikačního SW

Práce s databází

- databázový dotaz
 - výraz v dotazovacím jazyku
 - někdy se tímto pojmem označuje téměř jakákoli operace nad databází (např. v MS Access)
- výsledek dotazu
 - odpověď v podobě datové struktury
- v tomto předmětu
 - tvorba tabulek a jejich vazeb
 - naplnění tabulek daty
 - manipulace s daty v tabulkách

Návrh databáze

- návrh databáze lze považovat za jednu z disciplin SW inženýrství
 - nejprve musíme zjistit požadavky
 - pak databázi správně navrhnout
 - pak databázi správně vytvořit
 - pak....
- v drtivé většině případů je potřeba začít skutečně od začátku, tj. nezačínat rovnou třetím bodem...

Návrh databáze

- co zahrnuje „databázi správně navrhnout“?
- tři nejzákladnější úrovně
 - navrhnout celkovou obecnou strukturu databáze
 - konceptuální model (třídy, entity, vztahy, ...)
 - zvolit architekturu, platformu, DBMS a navrhnout, jak v tomto prostředí vytvořit vymyšlenou strukturu
 - logický model (tabulky, objekty, cizí klíče, ...)
 - optimalizovat fyzické uložení dat s ohledem na použití databáze
 - fyzický model (způsob uložení tabulek, indexy, ...)

Návrh databáze

- co zahrnuje „databázi správně navrhnout“?
- je to jako když se staví dům
 - architekt navrhne celkovou koncepci domu
 - splnění požadavků, velikost, tvar, vnitřní dispozice, ...
 - dále se vymyslí, jak se tato koncepce zrealizuje
 - železobetonový skelet s vyzdívkami a průvlaky, zavěšená skleněná fasáda, ...
 - nakonec se rozpracují detaily
 - kudy povedou trubky klimatizace a jakou budou mít světlost, kolik bude v kotelně kotlů a kde, ...

Návrh databáze

- tři úrovně pohledu na data – souhrn
 1. konceptuální schema
 2. databázové schema
 3. úložiště jako množina souborů
 3. úložiště jako množina bloků operačního systému
- pro každou úroveň pohledu navrhujeme vhodné řešení pomocí nějakého obecného modelu

Návrh databáze

- tři úrovně abstrakce, tři úrovně pohledu

1. konceptuální model

- nejvyšší úroveň abstrakce, modelujeme datové entity jako objekty reálného světa, nestaráme se o implementaci a architekturu
- obvykle grafický diagram
 - např. ER modelování, UML modelování
- řešíme, jaké kategorie dat budeme v databázi mít, jaké jsou mezi nimi vztahy a jaká na ně klademe omezení
 - např. zjistíme, že potřebujeme evidovat studenty, předměty, učitele a také vztahy mezi nimi – učitelé mohou učit předměty a studenti si můžou předměty zapisovat

Návrh databáze

- tři úrovně abstrakce, tři úrovně pohledu

2. logický model

- střední úroveň abstrakce, modelujeme entity jako struktury v konkrétním logickém modelu (třeba jako tabulky), pojmy konceptuálního modelování dostávají konkrétní podobu (stále se ale nezajímáme o efektivní implementaci)
- např. relační, objektově-relační, objektový model
- řešíme, do jakých struktur budeme data ukládat a jak budeme realizovat vztahy mezi konkrétními datovými prvky
 - např. budeme mít tabulky Učitel, Předmět, Student a to, že konkrétní učitel učí konkrétní předmět, vyřešíme „odkazem“ z tabulky Předmět do tabulky Učitel

Návrh databáze

- tři úrovně abstrakce, tři úrovně pohledu

3. fyzický model

- nízká úroveň abstrakce, implementace logického modelu v daných technických podmínkách
- uživatelé (programátoři aplikací, příležitostní uživatelé) jsou od této vrstvy odstíněni logickou vrstvou SŘBD
- optimalizace výkonu SŘBD a uložení dat tak, aby manipulace s nimi byla rychlá, zabezpečená a škálovatelná
- např. management datových souborů, indexování, B-stromy, transakční zpracování
- řešíme, jak uložíme naše tabulky na disk do souborů
 - např. pro každou tabulku zavedeme indexovaný soubor