

Návrh a implemetace databázových systémů

Business intelligence

Úvod

■ vývoj

- podniky se v rámci konkurenčního boje vždy snažily porozumět prostředí, v němž působí
 - nezbytný podklad pro dlouhodobé strategické plánování, ale i pro okamžité taktické manévry
- ještě nedávno neexistovaly dostatečné počítačové prostředky pro sběr, ukládání a analýzu těchto dat
 - i v situaci, kdy již v podniku existoval jakýsi IS, nebyla podpora tohoto typu běžná
- postupně však vznikaly potřebné standardy v ICT, které zpřístupnily obrovské objemy elektronických dat, jež se poté staly živnou půdou pro business intelligence

Úvod

- co to tedy je business intelligence?
 - business intelligence (BI) zahrnuje
 - procházení velkých objemů dat
 - extrakci důležitých informací
 - změna získaných informací na znalosti použitelné při řízení podniku
 - definice
 - BI je sada konceptů a metod pro zlepšení rozhodování podniků pomocí podpůrných systémů založených na faktech

Úvod

- proč nelze pro podporu rozhodování použít databáze, obsažené v informačních systémech?
 - ne vždy je IS podniku postaven na jedné DB
 - komponenty jako je účetní systém, správa skladu, personální agenda, správa objednávek, mají často své vlastní databáze
 - jednotlivé komponenty spolu sice komunikují, každá jednotlivá DB však má jinou strukturu, může používat jiné datové typy a formáty apod.
 - získávání integrovaných informací je tudíž téměř nemožné

Úvod

- proč nelze pro podporu rozhodování použít databáze, obsažené v informačních systémech?
 - provozní systémy a databáze nebyly konstruovány pro účel obchodního rozhodování
 - jsou dělené podle aplikačních oblastí (fakturace, řízení zásob, prodej produktů) a nikoli podle hlavních subjektů organizace (zákazníci, produkty, dodavatelé)
 - poskytují podrobná, aktuální a neustále se měnící data, ovšem pro rozhodování potřebujeme data sumarizovaná, historická, která se mění jen pomalu
 - jsou zaměřeny na aktuální provoz, nepotřebná starší data jsou archivována a nebývají snadno dostupná; pro rozhodování však často potřebujeme právě tuto historii

Úvod

- proč nelze pro podporu rozhodování použít databáze, obsažené v informačních systémech?
 - provozní systémy a databáze nebyly konstruovány pro účel obchodního rozhodování
 - jsou optimalizovány pro zpracování obřího množství jednoduchých a předvídatelných operací, zatímco pro rozhodování potřebujeme naopak zpracovat malé množství nepředvídatelných a komplikovaných operací
 - podporují paralelní přístup mnoha uživatelů, zatímco rozhodování je obvykle v rukách jen hrstky manažerů

Princip řešení

- princip řešení
 - datové sklady, online analytical processing (OLAP) a data mining
 - všechna provozní a archivní data „přechroupeme“ a uložíme znovu jinač a v jiné formě
 - na integrovaná data aplikujeme sofistikované analytické nástroje
 - využíváme především agregací – vypočítávání souhrnných informací z tisícovek a milionů záznamů

Datové sklady

- datový sklad
 - speciální DB systém, navržený pro podporu rozhodování pomocí integrovaného pohledu na data, jež jsou kopírována z provozních DB
 - zdrojem dat jsou provozní databáze, případně soubory a externí zdroje (web)
 - zdrojová data jsou extrahována, přetransformována a uložena do datového skladu
 - v datovém skladu jsou data uchovávána již v částečně sumarizované „předžvýkané“ podobě
 - to sice zvyšuje nároky na úložný prostor, ale zrychluje to práci – data se nemusejí stále znovu přepočítávat
 - mohou být současně uloženy různé úrovně sumarizace

Datové sklady

- datový sklad

- tedy tam, kde pro běžnou agendu máme databázi a nad ní pracující aplikační programy, pro účely BI máme datový sklad a nad ním speciální nástroje pro získávání komplexních informací
- datový sklad tedy uchovává de facto znovu to samé jako provozní DB, ale vše na jednom místě, vyčištěné, konzistentní a v takové struktuře, která vyhovuje obchodnímu rozhodování

Datové sklady

- data jsou
 - subjektivě orientovaná
 - organizována podle subjektů (zákazníci, produkty, prodej), nikoli podle aplikační oblasti (fakturace, sklad)
 - kvůli podpoře rozhodování
 - integrovaná
 - data shromážděna z různých aplikací v organizaci
 - zdrojová data často nekonzistentní a heterogenní
 - časově proměnlivá
 - platí jen pro určitý okamžik či interval
 - nevolatilní
 - aktualizována v pravidelných intervalech, nikoli online
 - nová data jsou vždy přidána, nenahrazují stará data


Datové sklady

■ srovnání OLTP a datového skladu

OLTP systém	Datový sklad
Obsahuje aktuální data	Obsahuje historická data
Obsahuje podrobná data	Obsahuje podrobná, slabě a silně sumarizovaná data
Data jsou dynamická	Data jsou většinou statická
Opakující se zpracování	<i>Ad hoc</i> , nestructurované a heuristické zpracování
Vysoká průchodnost transakcí	Střední až nízká průchodnost transakcí
Předvídatelné vzorce použití	Nepředvídatelné vzorce používání
Řízení transakcemi	Řízení analýzou
Podpora pro každodenní provozní rozhodování	Subjektově orientovaná
Slouží velkému počtu uživatelů	Podporují taktické a strategické rozhodování
	Slouží menšímu počtu uživatelů

Datové sklady

architektura datového skladu




Datové sklady

- struktura databáze datového skladu
 - často se používá hvězdicové schema
 - dimenzionální tabulky
 - odpovídají jednotlivým dimenzím problému a uchovávají možné hodnoty dat v dané dimenzi
 - použití pro vyhledávací podmínky
 - častá je separátní tabulka pro čas
 - pod nějakým ID uchovává třeba n-tici (hodina, den, týden, měsíc, rok)
 - tabulka faktů
 - PK: cizí klíče do dimenzionálních tabulek, de facto určení souřadnice daného bodu
 - číselné (ideálně...) informace k dané souřadnici v multidimenzionálním prostoru

Datové sklady

- hvězdicové schema



OLAP

- online analytical processing
 - analýza velkých objemů multidimenzionálních dat, agregovaných s různou úrovní podrobnosti
 - základní navigace a procházení
 - výpočty
 - komplexní analýzy
 - časové řady
- přirovnáno k SQL dotazu
 - OLAP dotaz se dotýká velkého množství záznamů
 - dotaz s agregacemi a GROUP BY
 - OLTP dotaz se týká malého množství záznamů
 - dotaz SELECT-FROM-WHERE bez agregací

OLAP

■ druhy OLAP

■ ROLAP – relační

- data ukládána v tabulkách, např. hvězdicové schema
- bitmapová indexace
- výhoda – schopnost přistupovat k velkým objemům dat
- nevýhoda – mnohdy slabá výkonnost (princip podobný dotazům SQL)

■ MOLAP – multidimenzionální krychle (**cubes**)

- data ukládána do vícerozměrných polí
 - použití nerelačních operátorů
- výhoda – rychlé vyhledání dat podle souřadnic
- nevýhoda – omezené množství dat, krychle je vytvořena naráz a nelze ji aktualizovat

ROLAP

■ základní operace

■ slicing and dicing

- slice – řez krychlí (klauzule WHERE)
- dice – tvorba podkrychlí (klauzule GROUP BY)

■ struktura dotazu

```
SELECT grouping attributes and aggregations  
FROM fact table joined with zero or more dimension tables  
WHERE certain attributes are constant  
GROUP BY grouping attributes;
```

■ příklad dotazu

```
Autos(serialNo, model, color)  
Dealers(name, city, state, phone)  
Days(day, week, month, year)  
Sales(serialNo, date, dealer, price)
```

```
SELECT color, SUM(price)  
FROM Sales NATURAL JOIN Autos  
WHERE model = 'Gobi'  
GROUP BY color;
```

potom *slicing* dle model

nejprve *dicing* dle color

ROLAP

■ základní operace

■ příklad dotazu

- dice: podle roku a dealera
- slice: konkrétní model, barva a roky

```
SELECT dealer, year, SUM(price)
FROM (Sales NATURAL JOIN Autos) JOIN Days ON date = day
WHERE model = 'Gobi' AND
      color = 'red' AND
      (year = 2001 OR year = 2002)
GROUP BY year, dealer;
```

■ postupné analýzy

- drill-down
 - zjemňování *dicingu* (např. seskupování podle měsíce místo roku, apod.)
 - soustředění se pouze na určité hodnoty (užší *slicing*)
- roll-up – opačný postup

MOLAP – cubes

- vícerozměrná krychle, která v každém „vnitřním bodě“ uchovává (agregované) hodnoty dané souřadnice
- navíc jsou uloženy agregace pro všechny kombinace dimenzí – operátor CUBE na zákl. data
- mějme např. tabulku se schematem

```
Sales(model, color, date, dealer, val, cnt)
```

- každý řádek uchovává tuto informaci:
 - kolik aut (cnt) daného modelu a barvy prodal daný dealer v daný den a za jako celkovou cenu (val)
- aplikace operátoru CUBE přidá řádky obsahující agregace přes jednu či více dimenzí (agregovaná dimenze značena ★)

MOLAP – cubes

```
('Gobi', 'red', '2001-05-21', 'Friendly Fred', 45000, 2)
```

The interpretation is that on May 21, 2001, dealer Friendly Fred sold two red Gobis for a total of \$45,000. The tuple

```
('Gobi', *, '2001-05-21', 'Friendly Fred', 152000, 7)
```

says that on May 21, 2001, Friendly Fred sold seven Gobis of all colors, for a total price of \$152,000. Note that this tuple is in CUBE(Sales) but not in Sales.

Relation CUBE(Sales) also contains tuples that represent the aggregation over more than one attribute. For instance,

```
('Gobi', *, '2001-05-21', *, 2348000, 100)
```

says that on May 21, 2001, there were 100 Gobis sold by all the dealers, and the total price of those Gobis was \$2,348,000.

```
('Gobi', *, *, *, 1339800000, 58000)
```

Says that over all time, dealers, and colors, 58,000 Gobis have been sold for a total price of \$1,339,800,000. Lastly, the tuple

```
(*, *, *, *, 3521727000, 198000)
```

tells us that total sales of all Aardvark models in all colors, over all time at all dealers is 198,000 cars for a total price of \$3,521,727,000. □

MOLAP – cubes

- nevýhoda tohoto řešení
 - agregace je buď přes nejmenší „jednotku“ dané dimenze (např. pro jeden den), nebo přes celou dimenzi (přes všechny dny)
 - nejsou uloženy agregace přes nějaké intervaly apod.
 - pokud bychom měli v krychli ukládat všechny možné kombinace seskupování, objem dat by neúnosně narostl
 - kromě toho, data by už neměla onu přehlednou strukturu (hodnota / hvězdička)
- řešení: **materialized views**

MOLAP – cubes

- materialized view
 - nějaká agregace hyperkrychle, která je pak použita pro dotazy

```
INSERT INTO SalesV1
  SELECT model, color, month, city,
         SUM(val) AS val, SUM(cnt) AS cnt
  FROM Sales JOIN Dealers ON dealer = name
  GROUP BY model, color, month, city;
```

Data mining

- data mining
 - prosté uložení dat v datovém skladu neposkytne samo o sobě žádoucí efekt
 - je třeba ukryté informace nějak extrahovat, „vydolovat“ (odtud název)
 - základní analýzu je analytik schopen provést na datovém skladu i bez pokročilých nástrojů
 - vzhledem k růstu objemu a složitosti dat ale mohou data skrývat neočekávané trendy či závislosti, které je obtížné odhalit => potřeba sofistikovaných technik data miningu

Data mining

- *data-mining query versus decision-support query*
- decision-support query
 - konkrétní otázka, na kterou chce manažer znát odpověď
 - **jaké jsou sumární prodeje aut podle barvy a roku?**
- data-mining query
 - otázka, která se ptá na abstraktnější věc
 - **jaké jsou faktory, které nejvíce ovlivnily prodeje aut?**
 - naivní implementace – zkusit mnoho decision-support dotazů a vybrat ten správný
 - naprosto nepoužitelné, trvalo by věčnost

Data mining

- data mining – příklady aplikace

- maloobchod

- identifikace nákupních vzorců zákazníků
 - hledání souvislostí mezi demografickými charakteristikami zákazníků
 - předvídání reakcí na marketingovou kampaň

- bankovníctví

- detekce vzorců podvodného užití kreditních karet
 - identifikace loajálních zákazníků
 - odhad útrat kreditní kartou podle skupin zákazníků

- pojišťovnictví

- analýza škoda
 - typování zákazníků, kteří si koupí nové produkty