

Programovací jazyky a překladače

Přednáška 6, poznámky

Jan Voráček

VŠPJ Jihlava, voracek@vspj.cz


Dnešní témata

- Konečné automaty, opakovací příklady (viz PP5)
- Úvod do syntaktické analýzy
- LL gramatiky
 - Vlastnosti a způsoby použití
 - Kontextové množiny FIRST a FOLLOW
 - Konverze obecné CFG and LL(1) gramatiku
 - Odstranění levé rekurze
 - Levá faktorizace
- Programová realizace LL(1) syntaktických analyzátorů (úvod)
 - Překlad rekurzivním sestupem
 - Tabulková implementace
- YACC/Bison?

Prezentace

- LR gramatiky, rozdělení a vlastnosti
- YACC, syntaktická analýza

Minimalizace KA 6 → 4



1

	a	b
A	A	B
B	E	C
C	C	D
D	F	C
E	D	E
F	B	E

	a	b
A	I	I
B	I	II
D	I	II
E	I	I
F	I	I

2

	a	b
A	i	ii
E	ii	i
F	ii	i



3

	a	b
B	i	ii
D	i	ii

4

	a	b
E	aa	a
F	aa	a

Výsledný minimální KA



1

	a	b
A	A	B
B	E	C
C	C	D
D	F	C
E	D	E
F	B	E

	a	b
A	I	I
B	I	II
D	I	II
E	I	I
F	I	I

2

	a	b
A	i	ii
E	ii	i
F	ii	i

3

	a	b
B	i	ii
D	i	ii

4

	a	b
E	aa	a
F	aa	a

Syntaktická analýza

```
<!DOCTYPE html PUBLIC "-//W3C//DTD  
<html dir="ltr" xmlns="http://www.  
<head>  
  <title>Hello World</title>  
  <meta http-equiv="Content-Type  
  <meta name="keywords" content  
  <meta name="description" cont  
  <meta name="content-language  
  <link rel="stylesheet" type  
</head>  
<body>  
  <div class="banner">  
  <div style="margin:0 au
```

Syntaktická analýza (parsing): úvodní přehled

- **LL (shora-dolů) a LR (zdola-nahoru)**
 - Na pomezí stojí tzv. **precedenční gramatiky**
 - LL: levý rozklad
 - LR: (inverzní) pravý rozklad
 - $Lx(i)$: i je počet vstupních symbolů (tokenů), které potřebujeme znát k deterministické funkci analyzátoru daného jazyka. Obvykle $i = 1$
- Určení LL gramatiky na množině bezkontextových gramatik (CFG):
 - Výpočet kontextových množin **FIRST** a **FOLLOW**
- Převod obecné CFG na LL gramatiku není obecně algoritmizovatelný a nejčastěji zahrnuje následující činnosti:
 - Odstranění levé rekurze (konečnost)
 - Levá faktorizace a levá rohová substituce
 - Odstranění konfliktu **FIRST-FIRST**
 - Pohlčení terminálu
 - Odstranění konfliktu **FIRST-FOLLOW**

Typické způsoby konstrukce syntaktického analyzátoru



- Ad-hoc
 - Zcela v intencích autorových tvůrčích schopností
- LL gramatiky
 - Rekurzivním sestupem
 - Řízený tabulkou
 - Konstruktoem (YACC/Bison) při konverzi na LR gramatiku
- LR gramatiky
 - Konstruktoem (YACC/Bison)

Analýza syntaxe = výstavba syntaktického stromu

- LL1 (shora dolů): zleva doprava, levá derivace
 - Expanze NT na vrcholu zásobníku nebo odstranění T ze vstupu
- LR1 (zdola nahoru): zleva doprava, pravá derivace
 - Redukce sekvence na vrcholu zásobníku NT nebo přesun T na zásobník

Srovnání obou přístupů

Zdola



Shora




Zdroj: <https://www.geeksforgeeks.org/bottom-up-or-shift-reduce-parsers-set-2/>

Analýza zdola nahoru

- LR(1) gramatiky:
 - Čte vstupní větu zleva doprava (L)
 - Provádí její (reverzní) pravý (= nejpravější) rozklad (R)
 - Deterministická predikace dalšího kroku na základě znalosti následujícího 1 vstupního tokenu (1)


Prováděný rozklad (výstavba stromu)



$\underline{E} \Rightarrow E + \underline{I} \Rightarrow E + T * \underline{F} \Rightarrow E + \underline{I} * n \Rightarrow$
 $\Rightarrow E + \underline{F} * n \Rightarrow \underline{E} + n * n \Rightarrow \underline{I} + n * n \Rightarrow$
 $\Rightarrow \underline{F} + n * n \Rightarrow n + n * n$


Reverzní směr zpracování vstupu (průběžné redukce)

Výstavba derivačního stromu zdola



LR překlad

Mějme gramatiku a vstupní řetězec *abbcde*




1	Start	→	a A B e
2	A	→	A b c
3			b
4	B	→	d

Jeho výsledný **pravý rozklad** je dán následující tabulkou:

Větná forma	Redukce	
	Pravidlo	Pozice
abbcde	3	2
a A bcde	2	4
a A de	4	3
a A B e	1	4
Start	—	—

LL překlad

Mějme gramatiku a vstupní řetězec *bbda*



1	Start	→	B a
2			c
3	B	→	b B
4			d

Jeho výsledný **levý rozklad** je dán následující tabulkou:

Větná forma	Expanze	
	Pravidlo	Pozice
Start	1	1
B a	3	1
b B a	3	1
bb B a	3	2
bbda	4	3
bbda	—	4

Syntaktická analýza

Miroslav Beneš
Dušan Kolář



LL(1) gramatiky

Miroslav Beneš

Dušan Kolář



Gramatika č. 1 pro 6. cvičení

(levá faktORIZACE)

$S \rightarrow AB$

$S \rightarrow AB$

$A \rightarrow ad \mid abAc \mid aBc$



$A \rightarrow aA'$

$A' \rightarrow d \mid bAc \mid Bc$

$B \rightarrow fA \mid f$



$B \rightarrow fB'$

$B' \rightarrow A \mid \varepsilon$

Gramatika č. 2 pro 6. cvičení

(odstranění levé rekurze)

$S \rightarrow id=E$

$E \rightarrow E+E \mid E * E \mid (E) \mid a \mid b$

$S \rightarrow id=E$

$E \rightarrow E+T \mid T$

$T \rightarrow T * F \mid F$

$F \rightarrow (E) \mid a \mid b$

$S \rightarrow id=E$

$E \rightarrow TE'$

$E' \rightarrow +TE' \mid \varepsilon$

$T \rightarrow FT'$

$T' \rightarrow *FT' \mid \varepsilon$

$F \rightarrow (E) \mid a \mid b$

Výpočet kontextových množin FIRST a FOLLOW

FIRST

X je terminál $\Rightarrow \text{First}(X) = \{X\}$

$X \rightarrow \varepsilon$ $\Rightarrow \varepsilon \in \text{First}(X)$

$X \rightarrow Y_1 Y_2 \dots Y_k$ $\Rightarrow \text{First}(Y_1 Y_2 \dots Y_k) \in \text{First}(X)$

Zde je navíc třeba zohlednit varianty, kdy $\varepsilon \in \text{First}(Y_i)$

FOLLOW

$\$ \in \text{Follow}(S)$

$A \rightarrow aB\beta$ $\Rightarrow \text{FIRST}(\beta) \subset \text{FOLLOW}(B).$

$A \rightarrow aB$ $\Rightarrow \text{FOLLOW}(A) \subset \text{FOLLOW}(B)$

$A \rightarrow aB\beta$ a $\varepsilon \in \text{First}(\beta)$ $\Rightarrow \text{FOLLOW}(A) \subset \text{FOLLOW}(B)$

$E \rightarrow T X$

$X \rightarrow + E$

$X \rightarrow \varepsilon$

$T \rightarrow \text{int } Y$


$T \rightarrow (E)$

$Y \rightarrow * T$


$Y \rightarrow \varepsilon$

1. *FIRST* pro terminály
2. *FIRST* pro ε
3. *FIRST* pro nenulované neterminály
4. *FIRST* pro nulované neterminály
5. *FOLLOW* pro nenulované vnitřní sousedství
6. *FOLLOW* pro nulované vnitřní sousedství
7. *FOLLOW* pro konec souboru
8. *FOLLOW* pro konec pravidla


Ukázky konstrukce množiny FOLLOW(A)



Případ 5




Případ 6



EOF

Případ 7 Případ 8



Follow (X)

$E \rightarrow T X$

$X \rightarrow + E$

$\mid \varepsilon$

$T \rightarrow \text{int } Y$

$\mid (E)$

$Y \rightarrow * T$

$\mid \varepsilon$

Symbol	FIRST	FOLLOW
(	(	
)	)	
+	+	
*	*	
int	int	
Y	e, *	+, \$,)
X	e, +	\$,)
T	int, (	+, \$,)
E	int, (	\$,)

Grammar

```

E → T X .
X → + E
   | .
T → int Y
   | ( E ).
Y → * T
   | .
    
```

- All nonterminals are reachable and realizable.
- The nullable nonterminals are: X Y.
- The endable nonterminals are: Y E X T.
- No cycles.

nonterminal	first set	follow set	nullable	endable
E	int (	)	no	yes
X	+	)	yes	yes
Y	*	) +	yes	yes
T	int (	) +	no	yes

The grammar is LL(1).

Zdroj: <http://smlweb.cpsc.ucalgary.ca/start.html>

FIRST

Upravená gramatika pro
aritmetické výrazy:

$E \rightarrow T E'$

$E' \rightarrow + T E' \mid \text{epsilon}$

$T \rightarrow F T'$

$T' \rightarrow * F T' \mid \text{epsilon}$

$F \rightarrow (E) \mid \text{int}$

$\text{FIRST}(E) \Rightarrow \text{FIRST}(T)$

$\text{FIRST}(E') = \{ +, \text{epsilon} \}$

$\text{FIRST}(T) \Rightarrow \text{FIRST}(F)$

$\text{FIRST}(T') = \{ *, \text{epsilon} \}$

$\text{FIRST}(F) = \{ (, \text{int} \}$

$\text{FIRST}(E) = \{ (, \text{int} \}$

$\text{FIRST}(T) = \{ (, \text{int} \}$

FOLLOW

$S \rightarrow E \$$

$E \rightarrow T E'$

$E' \rightarrow + T E' \mid \text{epsilon}$

$T \rightarrow F T'$

$T' \rightarrow * F T' \mid \text{epsilon}$

$F \rightarrow (E) \mid \text{int}$

$\text{FOLLOW}(E) \supseteq \text{FOLLOW}(S)$

$\text{FOLLOW}(E') \supseteq \text{FOLLOW}(E)$

$\text{FOLLOW}(T) \supseteq \text{FIRST}(E')$

$\text{FOLLOW}(T) \supseteq \text{FOLLOW}(E')$

$\text{FOLLOW}(T') \supseteq \text{FOLLOW}(T)$

$\text{FOLLOW}(F) \supseteq \text{FIRST}(T')$

$\text{FOLLOW}(F) \supseteq \text{FOLLOW}(T')$

$\text{FOLLOW}(S) = \{ \$ \}$

$\text{FOLLOW}(E) = \{ \$,) \}$

$\text{FOLLOW}(E') = \{ \$,) \}$

$\text{FOLLOW}(T) = \{ +, \$,), \text{epsilon} \}$

$\text{FOLLOW}(T') = \{ +, \$,), \text{epsilon} \}$

$\text{FOLLOW}(F) = \{ *, +, \$,), \text{epsilon} \}$

Implementace LL(1) analyzátoru

Miroslav Beneš
Dušan Kolář

