



UMĚLÁ INTELIGENCE

Přednáška 9

Úlohy rozhodování

Teorie **rozhodování** se zabývá metodami, které kombinují funkci užitku s teorií pravděpodobnosti tak, aby agent mohl vybrat akce, které maximalizují jeho očekávanou výkonnost.

Funkce užitku popisuje, co agent chce. Teorie pravděpodobnosti popisuje, čemu by měl agent věřit na základě pozorování a faktů. Teorie rozhodování pak říká, co by měl agent dělat.

Teorii rozhodování můžeme použít k vytvoření racionálního agenta, který ve stochastickém prostředí zvažuje všechny možné akce a pak vybere tu, která vede k nejlepšímu očekávanému výsledku.

Pro popis a řešení rozhodovacích problémů slouží rozhodovací sítě (grafy), které obsahují rozhodovací uzly, uzly užitku a uzly nejistoty.



Agent řeší sekvenční rozhodovací problém, tj. užitek agenta závisí na celé posloupnosti rozhodnutí.

SEKVENČNÍ ROZHODOVACÍ PROBLÉM

Ilustrační příklad:

Agent začíná na políčku [1,1] a v každém časovém kroku musí zvolit akci. V každém stavu má k dispozici akce Nahoru, Dolů, Doleva a Doprava. Interakce s prostředím skončí, když agent dosáhne jednoho z cílových stavů označených +1 nebo -1 a dostane odpovídající odměnu. Za každý přechod mezi necílovými stavy dostává -0,04. Prostředí je plně pozorovatelné, tedy agent vždy ví, kde se nachází.

Prostředí je stochastické, tedy výsledek akce je nejistý. Zamýšlený výsledek nastane s pravděpodobností 0,8, s pravděpodobností 0,2 se agent pohybuje v pravém úhlu od zamýšleného směru, při srážce se stěnou agent stojí.



MARKOVSKÝ ROZHODOVACÍ PROCES

Stejně jako v Přednášce 3 popisuje **přechodový model** výsledek každé akce v každém stavu. Zde je ale výsledek stochastický, takže $P(s' | s, a)$ znamená pravděpodobnost dosažení stavu s' , pokud je ve stavu s provedena akce a . Předpokládáme, že přechody jsou markovské, tj. pravděpodobnost dosažení stavu s' ze stavu s závisí pouze na stavu s , nikoli na historii předchozích stavů.

Funkce užitku pro sekvenční rozhodovací problém bude záviset na posloupnosti stavů a akcí (historii prostředí), a nikoli na jediném stavu. Zde za každý přechod ze stavu s do stavu s' prostřednictvím akce a obdrží agent **odměnu** $R(s, a, s')$. Odměny mohou být kladné nebo záporné. Pro náš konkrétní příklad je odměna $-0,04$ pro všechny přechody kromě těch, které vedou do cílových stavů (s odměnami $+1$ a -1). Užitek historie prostředí je celkový součet získaných odměn. Například pokud agent po 10 krocích dosáhne stavu $+1$, jeho celkový užitek bude $(9 \times -0,04) + 1 = 0,64$. Záporná odměna $-0,04$ agenta motivuje rychle dosáhnout stavu $(4,3)$, takže toto prostředí je stochastickým zobecněním prohledávacích problémů z Přednášky 3.

Shrnutí: sekvenční rozhodovací problém pro plně pozorovatelné stochastické prostředí s markovským přechodovým modelem a aditivními odměnami se nazývá **markovský rozhodovací proces (MDP)** a skládá se z množiny stavů (s počátečním stavem s_0), množiny akcí $A(s)$ v každém stavu, přechodového modelu $P(s' | s, a)$ a funkce odměny $R(s, a, s')$. Metody pro řešení MDP obvykle využívají dynamické programování, tj. zjednodušení problému rekurzivním rozdělením na menší části a zapamatováním si optimálních řešení těchto částí.

ŘEŠENÍ MARKOVSKÉHO ROZHODOVACÍHO PROBLÉMU

Ve stochastickém prostředí nelze vygenerovat pevnou posloupnost akcí vedoucích k cíli.

Řešení musí specifikovat, co má agent udělat pro každý stav, který může dosáhnout.

Řešení tohoto druhu se nazývá **politika**, značí se π ; $\pi(s)$ je akce doporučená politikou π pro stav s .

Nezáleží na tom, jaký je výsledek akce, výsledný stav je zahrnut v politice a agent ví, co má dělat dál.

Pokaždé, když je daná politika provedena počínaje počátečním stavem, stochastická povaha prostředí může vést k jiné historii prostředí. Kvalita politiky se proto měří očekávaným užitekem z možných historií prostředí, které se vygenerují pomocí dané politiky.

Optimální politika je taková politika, která přináší nejvyšší očekávaný užitek.

SLOVNÍČEK POJMŮ

- **funkce užitku** $U(s)$ = číslo, které definuje očekávanou celkovou odměnu pro konečný (terminální) stav, pokud je nyní agent ve stavu s
 - **funkce kvality** $Q(s,a)$ = očekávaný užitek, pokud agent ve stavu s podnikne akci a , součet odměn počínaje stavem s , při vykonání akce a
platí: $U(s) = \max_a Q(s,a)$
 - **funkce odměny** $R(s,a,s')$ = číslo, které odpovídá dílčí odměně za přechod ze stavu s do stavu s' pomocí akce a
 - **politika** $\pi(s) = a$, tj. přímé zobrazení stavů na akce
 - **přechodový model** $P(s' | s,a)$ --> udává, s jakou pravděpodobností se agent dostane do stavu s' po vykonání akce a , pokud je aktuálně ve stavu s
-

MDP

- aditivní odměny

$$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + R(s_1) + R(s_2) + \dots$$

- diskontované odměny

$$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots$$

- očekávaný užitek

$$U^\pi(s) = E \left[\sum_{t=0}^{\infty} \gamma^t R(S_t) \right]$$

- Bellmannova rovnice pro $U(s)$

$$U(s) = R(s) + \gamma \max_{a \in A(s)} \sum_{s'} P(s' | s, a) U(s')$$

Zdroje:

Russell, S. J., Norvig, P. *Artificial Intelligence: A Modern Approach*. 4. vyd. Pearson, 2021
